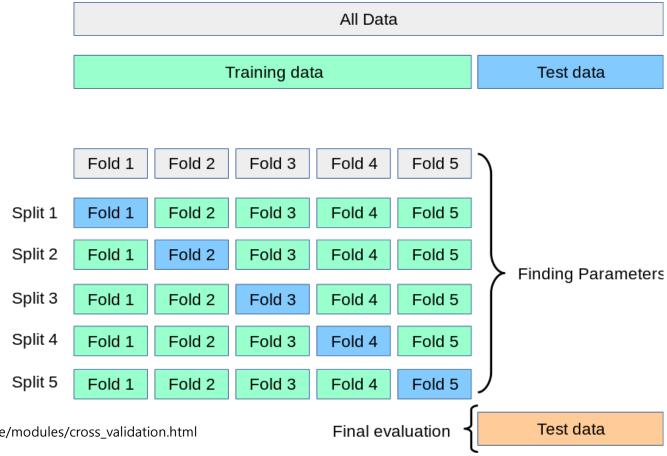
모델 평가방법과 오버피팅



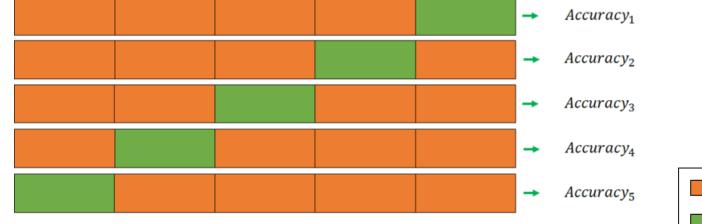




홀드아웃 방법(Holdout method)

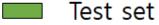






Legend

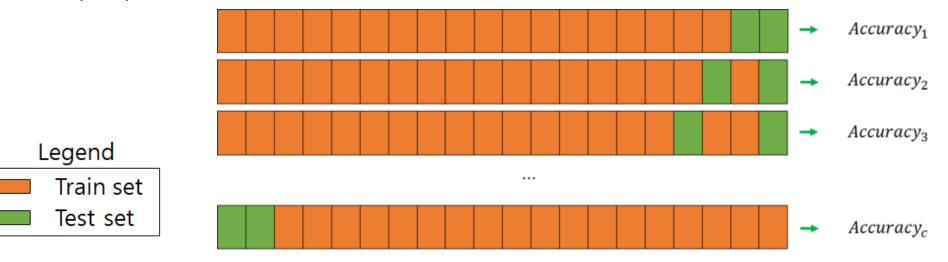
Train set



 $Accuracy = Average(Accuracy_1, \cdots, Accuracy_k)$



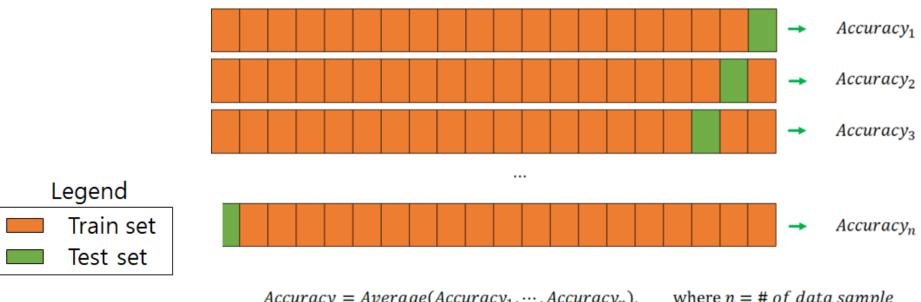
- 리브-p-아웃 교차 검증(Leave-p-out cross validation)
 - 전체 데이터(서로 다른 데이터 샘플들) 중에서 p개의 샘플을 선택하여 그것을 모델 검증에 사용하는 방법

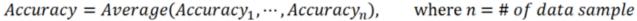


 $Accuracy = Average(Accuracy_1, \dots, Accuracy_c),$ where c = # of combinations of data sample



리브-원-아웃 교차 검증(Leave-one-out cross validation)







정확도 (Accuracy)

정확도

390+490/1000 = 0.88

	음성(예측)	양성(예측)
음성(실제)	390	110
양성(실제)	10	490

음성 400 양성 600

900/1000 = 0.9

	음성(예측)	양성(예측)
음성(실제)	900	0
양성(실제)	100	0

음성 1000 양성 0

정확도가 높으면 항상 좋은 모델?





정확도 (Accuracy)

- 불균형한(Imbalanced) 데이터에서는 Accuracy를 사용할 경우 잘못된 성능 예 측 결과
- 모델 성능 평가를 위해
 - Accuracy, Precision, Recall과 이를 이용한 F1 Score 등을 주로 사용



Confusion matrix

		실제 정답	
		True	False
분류	True	True Positive	False Positive
결과	False	False Negative	True Negative



Confusion matrix- Precision

TP/TP+FP

		실제 정답	
		True	False
분류	True	True Positive	False Positive
결과	False	False Negative	True Negative



Confusion matrix- Recall

TP/TP+FN

		실제 정답	
		True	False
분류	True	True Positive	False Positive
분류 결과	False	False Negative	True Negative



Confusion matrix

from sklearn.metrics import accuracy_score
from sklearn.metrics import confusion_matrix

```
label = [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 2, 2, 2, 2]
predict = [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 2, 2, 0]
```

print(confusion_matrix(label, predict))

- •0번 클래스의 경우 11개중 11개를 0으로, 0개를 1로, 0개를 2로 예측하였습니다.
- •1번 클래스의 경우 4개중 3개를 0으로, 1개를 1로, 0개를 2로 예측하였습니다.
- •2번 클래스의 경우 1개를 0으로, 1개를 1로, 2개를 2로 예측하였습니다



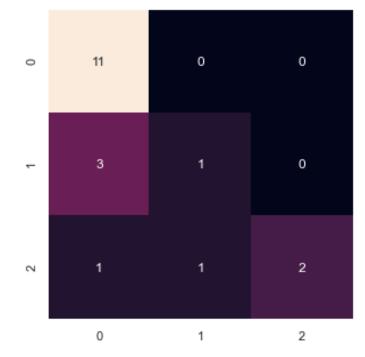
Confusion matrix

import seaborn as sns

```
label = [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 2, 2, 2, 2] predict = [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 2, 2, 0]
```

cmatrix = confusion_matrix(label, predict)

```
sns.set(rc={'figure.figsize':(6,5)})
sns.heatmap(data=cmatrix, annot=True)
```





선형회귀모델

```
mport matplotlib.pyplot as plt
import numpy as np
from sklearn import datasets
from sklearn.linear_model import LinearRegression
from sklearn.model selection import train test split
                                                                              # 편향(절편)
                                                                              print('Intercept: ', regr.intercept )
# 당뇨병 데이터셋 가져오기
diabetes = datasets.load diabetes()
                                                                              # 평균 제곱근 편차
                                                                              print("Mean squared error: %.2f" % np.mean((regr.predict(diabetes X test) - diabetes y test) ** 2))
diabetes_X = diabetes.data[:, np.newaxis, 2]
                                                                              # 훈련데이터 성능
#배열크기
                                                                              print('TrainSet score: %.2f' % regr.score(diabetes X train, diabetes y train))
diabetes X.shape
                                                                              # 테스트데이터 성능
# 훈련 세트, 테스트 세트 데이터 분리
                                                                              print('TestSet score: %.2f' % regr.score(diabetes X test, diabetes y test))
diabetes_X_train = diabetes_X[:-20]
diabetes_X_test = diabetes_X[-20:]
                                                                              # 도표 결과
                                                                              plt.scatter(diabetes X test, diabetes y test, color='black')
# 훈련 세트, 테스트 세트 타겠값 분리
                                                                              plt.plot(diabetes X test, regr.predict(diabetes X test), color='blue',
diabetes_y_train = diabetes.target[:-20]
                                                                                    linewidth=3)
diabetes_y_test = diabetes.target[-20:]
                                                                              plt.xticks(())
# 선형회귀 모델 생성
                                                                              plt.yticks(())
regr = LinearRegression()
                                                                              plt.show()
# 훈련 세트를 사용해서 모델 훈련
regr.fit(diabetes_X_train, diabetes_y_train)
# scikit-learn은 훈련데이터에서 유도된 속성은 항상 끝에 밑줄을 붙입니다.
#rear.coef , rear.intercept 처럼 밑줄을 붙임으로써 사용자가 지정한 변수와 구분할 수 있습니다.
#계수(가중치)
print('Coefficients: ', regr.coef_)
```



퍼셉트론

```
# Load required libraries
from sklearn import datasets
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import Perceptron
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
import numpy as np
# Load the iris dataset
iris = datasets.load_iris()
# Create our X and y data
X = iris.data
y = iris.target
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3)
sc = StandardScaler() #StandardScaler를 X_train 데이터가 mean = 0, variance = 1로 만들 수 있도록 학
sc.fit(X_train)
# Apply the scaler to the X training data
X_train_std = sc.transform(X_train)
# Apply the SAME scaler to the X test data
X test std = sc.transform(X test)
# Create a perceptron object with the parameters: 40 iterations (epochs) over the data, and a learning
rate of 0.1
ppn = Perceptron(n_iter=40, eta0=0.1, random_state=0)
# Train the perceptron
ppn.fit(X_train_std, y_train)
y_pred = ppn.predict(X_test_std)
print('Accuracy: %.2f' % accuracy_score(y_test, y_pred))
```



과적합



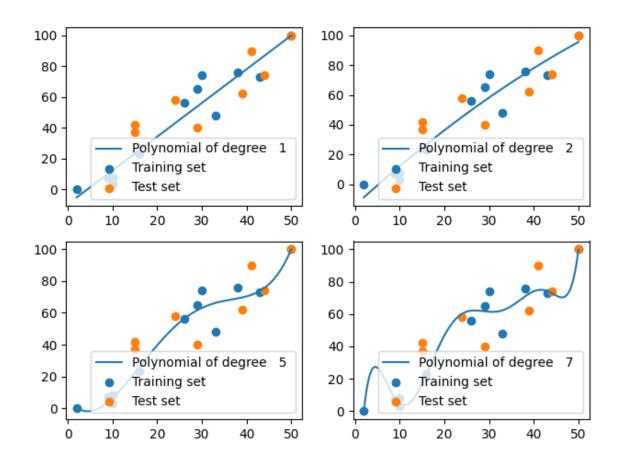
과적합(Overfitting)

Regression: M = 1M = 3M = 90 predictor too inflexible: predictor too flexible: cannot capture pattern fits noise in the data Classification: \mathbf{x}_{2} X_1 X_1

Copyright © 2014 Victor Lavrenko



과적합(Overfitting)





'과적합(Overfitting)

```
X train = x[0:12]
y \text{ train} = y[0:12]
X_{\text{test}} = x[12:]
y_{\text{test}} = y_{\text{12:}}
def polynomial_fit(degree = 1):
 return np.poly1d(np.polyfit(X train,y train,degree))
def plot polyfit(degree=1):
   p = polynomial_fit(degree)
   plt.scatter(X train, y train, label="Training set")
   plt.scatter(X_test, y_test, label="Test set")
   curve_x = np.arange(min(x), max(x), 0.01)
   plt.plot(curve_x, p(curve_x), label="Polynomial of degree {} ".format(degree))
   #plt.xlim((-1, 1))
   #plt.ylim((-1, np.max(y) + 0.1))
   print(r2 score(y, p(x)))
   plt.legend()
   plt.plot()
plt.subplot(2,2,1)
plot_polyfit(1)
plt.subplot(2,2,2)
plot polyfit(2)
plt.subplot(2,2,3)
plot_polyfit(5)
plt.subplot(2,2,4)
plot_polyfit(7)
plt.show()
```



이미지 및 코드 출처 https://github.com/ExcelsiorCJH/Hands-On-ML/ https://github.com/rickiepark/handson-ml2